

Modélisation Prédicative de la Température de Surface Terrestre à Partir de Données Satellitaires

Projet 10

Thématique : **IA & Data Engineering**

Mots-clés :

Satellite · Apprentissage supervisé · Régression
Python · Scikit-Learn · Climat · NASA/Copernicus

Encadrant : M. Benkherraf

Sources de données : NASA MODIS, Copernicus Land Service

Année académique : 2025–2026

Contents

Résumé exécutif	6
1 Introduction	7
1.1 Contexte et enjeux	7
1.2 Objectifs du projet	7
1.3 Organisation du rapport	7
2 Données et Méthodologie	8
2.1 Description du jeu de données	8
2.1.1 Sources satellitaires de référence	8
2.1.2 Variables du jeu de données	8
2.2 Modèle physique de génération	9
2.3 Méthodologie de modélisation	9
2.3.1 Pipeline de traitement	9
2.3.2 Métriques d'évaluation	10
3 Analyse Exploratoire des Données	11
3.1 Statistiques descriptives	11
3.2 Distribution de la variable cible	11
3.3 Analyse des corrélations	12
3.4 Relations bivariées	13
3.5 Évolution temporelle	14
4 Modélisation et Résultats	15
4.1 Modèles de régression évalués	15
4.2 Résultats comparatifs	15
4.3 Analyse du meilleur modèle : Gradient Boosting	16
4.3.1 Valeurs réelles vs prédites et résidus	16
4.3.2 Importance des variables	17
5 Visualisation Spatiale et Temporelle	18
5.1 Distribution spatiale des prédictions	18
5.2 Suivi temporel des prédictions	19
5.3 Profil latitudinal	19

6	Conclusion et Perspectives	20
6.1	Bilan du projet	20
6.2	Limites	20
6.3	Perspectives	20
A	Codes Python	22
A.1	Génération du dataset	22
A.2	Modélisation	22

List of Figures

2.1	Pipeline complet de modélisation	9
3.1	Distribution de la température de surface terrestre (LST). La distribution est approximativement symétrique, centrée autour de 16,9°C, avec une plage allant de −16°C (régions polaires en hiver) à +50°C (déserts en été).	11
3.2	Matrice de corrélation de Pearson entre toutes les variables. L’insolation ($r = +0,51$) et la latitude ($r = -0,46$) présentent les corrélations les plus fortes avec la LST, suivies par l’humidité ($r = -0,33$) et l’albédo ($r = -0,32$).	12
3.3	Nuages de points entre la LST et chaque variable prédictive. La droite de régression linéaire est tracée pour chaque paire. Le coefficient de corrélation r est indiqué dans le titre de chaque graphique.	13
3.4	Évolution temporelle de la LST sur la période 2018–2023. Le signal saisonnier est clairement visible avec des oscillations annuelles. La bande colorée représente ± 1 écart-type autour de la moyenne mensuelle.	14
4.1	Comparaison des métriques de performance (R^2 , RMSE, MAE) pour les cinq modèles évalués. Le Gradient Boosting domine sur toutes les métriques.	16
4.2	<i>Gauche</i> : Nuage de points réel vs prédit pour le Gradient Boosting ($R^2 = 0,9439$). Les points s’alignent près de la droite idéale $y = x$. <i>Droite</i> : Distribution des résidus, centrée en zéro ($\mu \approx 0$) et approximativement normale, indiquant l’absence de biais systématique.	16
4.3	Importance relative des variables géophysiques dans le modèle Gradient Boosting, calculée par l’impureté de Gini. L’insolation et le jour de l’année (saisonnalité) dominant, suivis de la latitude et de l’altitude.	17
5.1	Carte de la distribution spatiale de la LST réelle (gauche) et prédite (droite) par le Gradient Boosting. Le gradient latitudinal est bien reproduit, avec des températures élevées aux basses latitudes et basses aux latitudes élevées. L’échelle de couleur commune facilite la comparaison visuelle.	18
5.2	Comparaison temporelle des moyennes mensuelles de la LST réelle et prédite (haut) et erreur mensuelle correspondante (bas). Le modèle reproduit fidèlement la saisonnalité annuelle. Les erreurs mensuelles restent inférieures à 1°C en valeur absolue.	19

- 5.3 Profil latitudinal moyen de la LST. Le modèle capture correctement le gradient méridional, avec un maximum thermique autour de l'équateur ($T \approx 28^{\circ}\text{C}$) et des valeurs basses aux latitudes élevées ($T \approx 5^{\circ}\text{C}$). L'écart entre courbe réelle et prédite est très faible ($< 1^{\circ}\text{C}$ sur tout le profil). . . . 19

List of Tables

2.1	Sources satellitaires de référence	8
2.2	Description des variables du jeu de données	9
3.1	Statistiques descriptives du jeu de données	11
4.1	Présentation des modèles de régression	15
4.2	Performances comparées des modèles de régression sur le jeu de test	15

Résumé exécutif

Ce rapport présente une étude complète de modélisation prédictive de la **température de surface terrestre** (Land Surface Temperature, LST) à partir de données géophysiques satellitaires. Le projet s'inscrit dans la thématique IA & Data Engineering et vise à démontrer comment les techniques modernes d'apprentissage automatique permettent de prédire une variable climatique clé à partir de variables satellitaires observables.

Démarche adoptée :

- Construction d'un jeu de données représentatif de 2000 observations couvrant la période 2018–2023, incluant 8 variables géophysiques (latitude, altitude, NDVI, albédo, couverture nuageuse, humidité, insolation, jour de l'année).
- Analyse exploratoire approfondie : statistiques descriptives, matrices de corrélation, visualisations spatiotemporelles.
- Entraînement et évaluation comparative de 5 modèles de régression.
- Visualisation de la distribution spatiale et temporelle des prédictions.

Résultat clé : Le modèle **Gradient Boosting** offre les meilleures performances avec un coefficient de détermination $R^2 = 0,9439$ et une erreur quadratique moyenne RMSE = 3,26 °C sur le jeu de test. L'insolation et la latitude s'avèrent être les variables les plus influentes dans la prédiction.

1. Introduction

1.1 Contexte et enjeux

La température de surface terrestre (LST) est un paramètre fondamental en télédétection et en climatologie. Elle représente la température radiométrique de la surface, mesurée dans l'infrarouge thermique par des capteurs embarqués à bord de satellites d'observation tels que **MODIS** (NASA) et **Sentinel-3** (Copernicus). La LST diffère de la température de l'air mesurée en station météorologique : elle reflète directement l'état énergétique de la surface, conditionné par l'albédo, la couverture végétale, l'humidité et le bilan radiatif.

Pourquoi la LST est-elle importante ? Elle intervient dans les études d'îlots de chaleur urbains, la prévision de sécheresses agricoles, la modélisation du cycle de l'eau et le suivi du changement climatique à l'échelle régionale et globale.

1.2 Objectifs du projet

Conformément au cahier des charges fourni par ECAM-EPMI, ce projet poursuit quatre objectifs opérationnels :

1. **Collecter et préparer** des données satellitaires géophysiques représentatives.
2. **Entraîner un modèle de régression** supervisé capable de prédire la LST.
3. **Évaluer la performance** du modèle par des métriques rigoureuses et une validation croisée.
4. **Visualiser** la distribution spatiale et temporelle des prédictions.

1.3 Organisation du rapport

Le rapport est structuré en cinq chapitres : (1) introduction, (2) description des données et méthodologie, (3) analyse exploratoire, (4) modélisation et résultats, (5) visualisations et interprétation. Les codes Python complets sont fournis en annexe.

2. Données et Méthodologie

2.1 Description du jeu de données

2.1.1 Sources satellitaires de référence

Le jeu de données utilisé s'appuie sur les relations géophysiques documentées par les produits satellitaires suivants :

Table 2.1: Sources satellitaires de référence

Source	Instrument	Variable	Résolution
NASA MODIS	Terra/Aqua	LST, NDVI, Albédo	1 km
Copernicus	Sentinel-3 SLSTR	LST thermique	1 km
NASA MERRA-2	Réanalyse	Humidité, Insolation	0.5°
SRTM/ASTER	DEM	Altitude	30 m

2.1.2 Variables du jeu de données

Le dataset contient **2 000 observations** couvrant la période **2018–2023** avec une couverture spatiale globale (-60 à $+60$ de latitude). Les variables sont décrites dans le tableau suivant :

Table 2.2: Description des variables du jeu de données

Variable	Unité	Plage	Description
latitude	°	[−60; +60]	Latitude géographique
longitude	°	[−180; +180]	Longitude géographique
altitude_m	m	[0; 2 500]	Altitude au-dessus du niveau de la mer
ndvi	—	[0; 1]	Normalized Difference Vegetation Index
albedo	—	[0.05; 0.85]	Réflectance de surface
cloud_cover_pct	%	[0; 100]	Taux de couverture nuageuse
humidity_pct	%	[10; 100]	Humidité relative
insolation_wm2	W/m ²	[0; 800]	Insolation solaire
day_of_year	j	[1; 365]	Jour julien (saisonnalité)
lst_celsius	°C	[−16; +50]	Variable cible : LST

2.2 Modèle physique de génération

La variable cible T_s (LST en °C) est modélisée par la relation physique suivante, inspirée du bilan radiatif de surface :

$$T_s = T_0 - \kappa_\phi |\phi| + A \sin\left(\frac{2\pi d}{365}\right) - \Gamma z + \delta_\alpha (1 - \alpha) + \beta V + \gamma H + \lambda E - \mu C + \varepsilon \quad (2.1)$$

où ϕ est la latitude, d le jour de l'année, z l'altitude, α l'albédo, V le NDVI, H l'humidité, E l'insolation, C la couverture nuageuse et $\varepsilon \sim \mathcal{N}(0, 2.5^2)$ le bruit de mesure.

2.3 Méthodologie de modélisation

2.3.1 Pipeline de traitement




Figure 2.1: Pipeline complet de modélisation

2.3.2 Métriques d'évaluation

Trois métriques sont utilisées pour évaluer les modèles :

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2} \quad (2.2)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i| \quad (2.3)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (\hat{y}_i - y_i)^2}{\sum_{i=1}^n (\bar{y} - y_i)^2} \quad (2.4)$$

où y_i est la valeur réelle, $\hat{y}_i$ la valeur prédite et $\bar{y}$ la moyenne des valeurs réelles.

3. Analyse Exploratoire des Données

3.1 Statistiques descriptives

Table 3.1: Statistiques descriptives du jeu de données

Variable	Min	Q1	Médiane	Moyenne	Q3	Max
Latitude (°)	−59.6	−31.4	0.9	−0.2	30.1	60.0
Altitude (m)	0.2	44.0	223	383	563	2 479
NDVI	0.01	0.27	0.42	0.42	0.57	0.89
Albédo	0.06	0.16	0.23	0.24	0.30	0.82
Nuages (%)	0.0	28.4	40.7	40.0	51.9	90.5
Humidité (%)	10.0	47.6	59.4	58.9	70.7	100.0
Insolation (W/m ²)	0.0	97.0	186	186	274	674
LST (°C)	−16.0	6.8	16.8	16.9	26.5	50.2

3.2 Distribution de la variable cible




Figure 3.1: Distribution de la température de surface terrestre (LST). La distribution est approximativement symétrique, centrée autour de 16,9°C, avec une plage allant de −16°C (régions polaires en hiver) à +50°C (déserts en été).

3.3 Analyse des corrélations




Figure 3.2: Matrice de corrélation de Pearson entre toutes les variables. L'insolation ($r = +0,51$) et la latitude ($r = -0,46$) présentent les corrélations les plus fortes avec la LST, suivies par l'humidité ($r = -0,33$) et l'albédo ($r = -0,32$).

Interprétation des corrélations

- **Insolation (+0,51)** : Plus l'énergie solaire reçue est élevée, plus la surface se réchauffe. C'est la relation physique fondamentale.
- **Latitude (-0,46)** : Les régions équatoriales reçoivent plus d'énergie solaire ; la LST décroît avec la latitude absolue.
- **Humidité (-0,33)** : L'eau absorbe l'énergie thermique, réduisant la LST par évapotranspiration.
- **Albédo (-0,32)** : Une surface réfléchissante (glace, désert clair) réfléchit davantage d'énergie, réduisant l'absorption.

3.4 Relations bivariées

Relations entre LST et variables géophysiques




Figure 3.3: Nuages de points entre la LST et chaque variable prédictive. La droite de régression linéaire est tracée pour chaque paire. Le coefficient de corrélation r est indiqué dans le titre de chaque graphique.

3.5 Évolution temporelle




Figure 3.4: Évolution temporelle de la LST sur la période 2018–2023. Le signal saisonnier est clairement visible avec des oscillations annuelles. La bande colorée représente ± 1 écart-type autour de la moyenne mensuelle.

4. Modélisation et Résultats

4.1 Modèles de régression évalués

Cinq modèles de régression supervisée ont été comparés, allant des approches linéaires classiques aux méthodes d'ensemble :

Table 4.1: Présentation des modèles de régression

Modèle	Principe	HyperparaMètres
Régression linéaire	Minimisation des MCO	—
Ridge	Régularisation L_2	$\alpha = 1,0$
Lasso	Régularisation L_1 , sélection de variables	$\alpha = 0,1$
Random Forest	Ensemble d'arbres de décision	$n = 150$, depth= 12
Gradient Boosting	Boosting séquentiel	$n = 200$, depth= 5, $\eta = 0,05$

4.2 Résultats comparatifs

Table 4.2: Performances comparées des modèles de régression sur le jeu de test

Modèle	RMSE (°C)	MAE (°C)	R^2	CV R^2
Régression Linéaire	7,538	6,040	0,7004	$0,692 \pm 0,023$
Ridge ($\alpha = 1$)	7,538	6,041	0,7004	$0,692 \pm 0,023$
Lasso ($\alpha = 0,1$)	7,527	6,059	0,7013	$0,692 \pm 0,021$
Random Forest	3,726	2,990	0,9268	$0,924 \pm 0,005$
Gradient Boosting	3,262	2,598	0,9439	$0,938 \pm 0,007$




Figure 4.1: Comparaison des métriques de performance (R^2 , RMSE, MAE) pour les cinq modèles évalués. Le Gradient Boosting domine sur toutes les métriques.

4.3 Analyse du meilleur modèle : Gradient Boosting

4.3.1 Valeurs réelles vs prédites et résidus




Figure 4.2: *Gauche* : Nuage de points réel vs prédit pour le Gradient Boosting ($R^2 = 0,9439$). Les points s'alignent près de la droite idéale $y = x$. *Droite* : Distribution des résidus, centrée en zéro ($\mu \approx 0$) et approximativement normale, indiquant l'absence de biais systématique.

4.3.2 Importance des variables




Figure 4.3: Importance relative des variables géophysiques dans le modèle Gradient Boosting, calculée par l'impureté de Gini. L'insolation et le jour de l'année (saisonnalité) dominant, suivis de la latitude et de l'altitude.

Interprétation de l'importance des variables

- **Insolation** et **jour de l'année** sont les variables les plus discriminantes : elles capturent le forçage radiatif saisonnier, principal moteur de la LST.
- **Latitude** encode le gradient thermique méridien et la géométrie d'éclairement solaire.
- **Altitude** reflète le gradient adiabatique ($-6^{\circ}\text{C}/\text{km}$).
- **NDVI** et **albédo** jouent un rôle modulé par l'occupation du sol.

5. Visualisation Spatiale et Temporelle

5.1 Distribution spatiale des prédictions




Figure 5.1: Carte de la distribution spatiale de la LST réelle (gauche) et prédite (droite) par le Gradient Boosting. Le gradient latitudinal est bien reproduit, avec des températures élevées aux basses latitudes et basses aux latitudes élevées. L'échelle de couleur commune facilite la comparaison visuelle.

5.2 Suivi temporel des prédictions




Figure 5.2: Comparaison temporelle des moyennes mensuelles de la LST réelle et prédite (haut) et erreur mensuelle correspondante (bas). Le modèle reproduit fidèlement la saisonnalité annuelle. Les erreurs mensuelles restent inférieures à 1°C en valeur absolue.

5.3 Profil latitudinal




Figure 5.3: Profil latitudinal moyen de la LST. Le modèle capture correctement le gradient méridional, avec un maximum thermique autour de l'équateur ($T \approx 28^\circ\text{C}$) et des valeurs basses aux latitudes élevées ($T \approx 5^\circ\text{C}$). L'écart entre courbe réelle et prédite est très faible ($< 1^\circ\text{C}$ sur tout le profil).

6. Conclusion et Perspectives

6.1 Bilan du projet

Ce projet a permis de démontrer la faisabilité d'un modèle prédictif de la température de surface terrestre à partir de variables géophysiques satellitaires. Les quatre objectifs initiaux ont été atteints :

- ✓ **Collecte et préparation** : Jeu de données de 2000 observations, 9 variables, aucune valeur manquante.
- ✓ **Modèle de régression** : Cinq modèles évalués ; le **Gradient Boosting** identifié comme optimal.
- ✓ **Évaluation** : $R^2 = 0,9439$, $RMSE = 3,26^\circ C$, validation croisée 5-fold cohérente ($0,938 \pm 0,007$).
- ✓ **Visualisation** : Cartes spatiales, évolution temporelle, profil latitudinal.

Performance synthétique du meilleur modèle

$$R^2 = 0,9439$$

$$RMSE = 3,26^\circ C$$

$$MAE = 2,60^\circ C$$

6.2 Limites

- Le jeu de données est simulé à partir de relations physiques connues ; des données réelles MODIS/Copernicus pourraient révéler des phénomènes non linéaires supplémentaires.
- L'influence du type d'occupation du sol (forêt, désert, océan, glace) n'est pas explicitement modélisée.
- La résolution temporelle quotidienne ne permet pas de capturer les cycles diurnes de la LST.

6.3 Perspectives

- Intégration de données réelles via les APIs **NASA Earthdata** et **Copernicus Open Access Hub**.

- Utilisation de réseaux de neurones profonds (**CNN** sur images satellitaires multi-spectrales) pour exploiter la dimension spatiale.
- Déploiement d'un tableau de bord interactif **Streamlit** pour la visualisation en temps réel des prédictions.
- Extension à la prédiction à moyen terme (prévision de vagues de chaleur).

A. Codes Python

A.1 Génération du dataset

```
1 import numpy as np
2 import pandas as pd
3
4 np.random.seed(42)
5 n_samples = 2000
6 dates = pd.date_range(start='2018-01-01', periods=n_samples, freq='D')
7 latitude = np.random.uniform(-60, 60, n_samples)
8 altitude = np.abs(np.random.normal(300, 400, n_samples))
9 day_of_year = np.array([d.timetuple().tm_yday for d in dates])
10 season_signal = np.sin(2 * np.pi * day_of_year / 365.25)
11
12 ndvi = np.clip(0.4 + 0.3*season_signal + 0.1*np.cos(np.radians(latitude))
13               + np.random.normal(0, 0.1, n_samples), 0, 1)
14 albedo = np.clip(0.25 - 0.15*np.cos(np.radians(latitude))*season_signal
15                 + np.random.normal(0, 0.05, n_samples), 0.05, 0.85)
16 insolation = np.clip(250 + 150*np.cos(np.radians(latitude))*(0.5+0.5*
17                      season_signal)
18                  + np.random.normal(0, 20, n_samples), 0, 800)
19 lst = (25 - 0.45*np.abs(latitude) + 12*season_signal - 0.006*altitude
20       + 8*(1-albedo) + 5*ndvi + 0.015*insolation
21       + np.random.normal(0, 2.5, n_samples))
```

Listing A.1: generate_dataset.py — Construction du jeu de données satellitaires

A.2 Modélisation

```
1 from sklearn.ensemble import GradientBoostingRegressor
2 from sklearn.model_selection import train_test_split, cross_val_score
3 from sklearn.metrics import mean_squared_error, r2_score
4 import numpy as np
5
6 features = ['latitude', 'altitude_m', 'ndvi', 'albedo',
7            'cloud_cover_pct', 'humidity_pct', 'insolation_wm2',
8            'day_of_year']
9 X = df[features].values
10 y = df['lst_celsius'].values
```

```
11 X_train, X_test, y_train, y_test = train_test_split(  
12     X, y, test_size=0.2, random_state=42)  
13  
14 model = GradientBoostingRegressor(  
15     n_estimators=200, max_depth=5, learning_rate=0.05, random_state=42)  
16 model.fit(X_train, y_train)  
17  
18 y_pred = model.predict(X_test)  
19 rmse = np.sqrt(mean_squared_error(y_test, y_pred))  
20 r2    = r2_score(y_test, y_pred)  
21 print(f"RMSE : {rmse:.3f} degC | R2 : {r2:.4f}")
```

Listing A.2: modelisation.py — Entraînement et évaluation des modèles